

企业级应用软件设计与开发

期末大作业报告

TutorMind: 基于 LangGraph 的一对一智能学习辅导系统

方向：方向一：Agentic AI 原生开发

学号：2025303034

姓名：刘梦豪

专业：软件工程

指导教师：戚欣

提交日期：2026 年 6 月 22 日

目录

一、选题背景与设计思想.....	1
1.1 问题定义.....	1
1.2 现有方案不足.....	1
1.3 项目价值.....	1
1.4 技术路线.....	1
二、Specs 规格文档	2
2.1 Product Spec	2
2.2 Architecture Spec	2
2.3 API Spec	2
三、系统架构与设计.....	3
3.1 核心架构图.....	3
3.2 Agent 交互流程	4
3.3 LangGraph workflow 设计	4
3.4 数据流设计.....	5
3.5 记忆机制设计.....	6
3.6 前后端交互设计.....	6
3.7 RAG 与苏格拉底教学流程	7
四、关键实现与代码展示.....	8
4.1 TutorState 状态定义.....	8
4.2 LangGraph workflow 构建	8
4.3 苏格拉底导师 Agent	9
4.4 四层记忆实现.....	9
4.5 多轮对话支持.....	10
4.6 AI IDE 使用说明	10
4.7 配置文件.....	14
五、测试与评估.....	14
5.1 功能测试.....	14
5.2 Agent 行为评估	15
5.3 Demo 截图	15
六、系统升级与扩展.....	19
6.1 可扩展架构.....	19
6.2 下一阶段计划.....	19
6.3 AI 能力演进路径	20
七、课程总结.....	20
7.1 个人收获.....	20
7.2 工程思维转变.....	20
7.3 对课程的建议.....	21

一、选题背景与设计思想

1.1 问题定义

在传统的在线教育场景中，学生往往面临以下痛点：一是缺乏个性化的学习辅导，大班教学模式难以针对每个学生的知识基础和学习风格进行差异化教学；二是学生在遇到问题时通常直接获得标准答案，缺少引导式思考的过程，导致知识掌握不牢固；三是学习过程中的对话历史难以被有效利用，无法形成持续进化的知识库。

TutorMind 项目旨在构建一个基于多智能体协作的一对一智能学习辅导系统，通过 LangGraph 状态机编排多个专门化 AI Agent，为学生提供苏格拉底式的个性化教学体验。系统能够自动收集学生信息、检索历史知识库、进行递进式引导教学，并在知识库未命中时通过实时搜索兜底，同时支持基于完整对话历史的多轮连贯交互。

1.2 现有方案不足

当前市场上的 AI 教育产品大多采用单 Agent 架构，存在以下不足：（1）功能耦合严重，信息收集、知识检索、教学引导等逻辑混杂在一起，难以维护和扩展；（2）缺乏系统化的记忆机制，多轮对话往往只依赖 LLM 的上下文窗口，无法持久化存储和跨会话复用；（3）缺少 RAG（检索增强生成）与苏格拉底教学法的有机结合，要么直接给答案，要么引导过于生硬；（4）缺乏可观测性和状态管理，Agent 的决策过程对用户和开发者均不透明。

1.3 项目价值

TutorMind 的核心价值在于：（1）采用 SDD（规格驱动开发）方法论，从 Product Spec、Architecture Spec 到 API Spec 分层设计，确保工程规范性；（2）基于 LangGraph StateGraph 实现真正的多智能体状态机编排，各 Agent 职责清晰、协作有序；（3）构建四层记忆机制（短期记忆 + 长期记忆 + 向量记忆 + Checkpoint），实现对话历史的有效利用；（4）融合 RAG 向量检索与苏格拉底引导教学，在知识库命中时通过递进式提问帮助学生自行推导答案；（5）支持 SSE 流式传输、Markdown/LaTeX 公式渲染、多会话管理，提供生产级的用户体验。

1.4 技术路线

本项目采用以下核心技术栈：

- AI IDE: Trae CN
- LLM: 阿里云百炼 DashScope（通义千问 qwen-plus）
- Agent 框架: LangGraph + LangChain
- 后端框架: FastAPI + Python 3.11+
- 向量数据库: ChromaDB
- 结构化存储: SQLite

- 实时搜索：Tavily Search API
- 前端：React 18 + TypeScript + Tailwind CSS
- 容器化：Docker + Docker Compose
- 协议：SSE 流式传输、REST API

二、Specs 规格文档

2.1 Product Spec

Product Spec 定义了 TutorMind 的产品目标、用户画像和核心功能矩阵。目标用户为需要一对一学习辅导的 K12 及高等教育学生。核心功能包括：学生信息自动收集与画像构建、知识库优先检索与苏格拉底引导教学、实时搜索兜底、多轮对话支持、自适应教学风格调整、流式响应与公式渲染、会话管理与用户隔离。

产品采用对话式交互范式，学生通过自然语言输入问题，系统根据学生画像和对话历史，自动选择最合适的 Agent 进行处理，并以流式方式返回格式化的教学回复。

2.2 Architecture Spec

Architecture Spec 定义了系统的分层架构和各层职责。系统分为五层：

- (1) 用户层：学生通过 Web 前端与系统交互；
- (2) 前端层：React 18 + TypeScript 实现，包含 ChatPanel 聊天面板和 Sidebar 会话管理；
- (3) API 网关层：FastAPI 提供 RESTful API 和 SSE 流式端点；
- (4) Agent 层：LangGraph StateGraph 编排五个专门化 Agent（Orchestrator、InfoCollector、KnowledgeRetriever、SocraticTutor、SearchAgent）；
- (5) 基础设施层：四层记忆机制 + 外部服务（DashScope LLM / Embedding、Tavily Search）。

核心设计原则：状态驱动（所有 Agent 共享 TutorState）、职责单一（每个 Agent 只负责一个教学环节）、记忆分层（短期/长期/向量/Checkpoint 各司其职）、可观测性（结构化日志 + 健康检查）。

2.3 API Spec

系统核心 API 端点定义如表 2. 1：

端点	方法	说明
/api/chat/	POST	非流式对话，返回完整回复
/api/chat/stream	POST	SSE 流式对话，实时返回字

		符
/api/chat/history/{student_id}/{session_id}	GET	获取指定会话历史记录
/api/chat/sessions/{student_id}	GET	获取学生所有会话列表
/api/chat/create_session/{student_id}	POST	创建新会话
/api/chat/session/{student_id}/{session_id}	DELETE	删除会话
/health	GET	健康检查, 返回系统状态

表 2. 1 系统核心 API 端点定义

请求/响应模型采用 Pydantic 进行严格校验，核心模型包括 ChatRequest(student_id、session_id、message)、ChatResponse(reply、agent_name、stage、is_guided、metadata)和 StudentProfile(name、age、education、is_weak_foundation)。

三、系统架构与设计

3.1 核心架构图

TutorMind 采用分层多智能体架构，如图 3. 1 所示，由 LangGraph StateGraph 作为核心编排引擎，五个专门化 Agent 通过共享 TutorState 状态对象协作完成教学任务。




图 3. 1 TutorMind 系统总体架构图

3.2 Agent 交互流程

系统包含五个核心 Agent，各司其职并通过 Orchestrator 统一协调，多 Agent 协作交互图如图 3. 2 所示：

- (1) OrchestratorAgent: 编排器，提供统一 LLM 调用接口和记忆管理；
- (2) InfoCollectorAgent: 信息收集器，负责学生画像构建和资料更新意图识别；
- (3) KnowledgeRetrieverAgent: 知识检索器，基于 ChromaDB 进行 RAG 向量检索；
- (4) SocraticTutorAgent: 苏格拉底导师，执行递进式引导教学，支持多轮历史；
- (5) SearchAgent: 搜索代理，调用 Tavily API 进行实时搜索兜底，支持多轮历史。




图 3. 2 TutorMind 多智能体协作交互图

3.3 LangGraph workflow 设计

LangGraph workflow 是系统的核心决策引擎，采用 StateGraph 定义节点和条件边，实现教学流程的状态机编排。LangGraph workflow 状态机如图 3. 3 所示， workflow 入口为 `check_student_info`，根据学生信息完整性进行条件路由：信息不完整时进入 `collect_info` 收集信息；信息完整时进入 `search_knowledge_base` 进行知识库检索。知识库检索后根据是否命中（相似度 ≥ 0.75 ）路由到 `socratic_teach` 或 `tavily_search`。

TutorMind LangGraph Workflow State Machine




图 3. 3 TutorMind LangGraph workflow状态机

3.4 数据流设计

TutorMind 的数据流设计如图 3. 4 所示，以 TutorState 为核心载体，贯穿输入层、处理层、存储层和输出层。输入层接收学生文本输入、学生画像数据和会话历史消息；处理层通过 LangGraph 状态机进行 Agent 路由决策和 LLM 调用推理；存储层通过 SQLite、ChromaDB 和内存滑动窗口实现多层记忆持久化；输出层通过 SSE 流式传输返回格式化响应，前端进行 Markdown/LaTeX 渲染。

TutorMind Data Flow Design




图 3. 4 TutorMind 数据流设计

3.5 记忆机制设计

如图 3. 5 所示，系统设计了四层记忆机制，解决不同时间尺度和语义粒度的记忆需求：

（1）短期记忆：基于内存的滑动窗口，每会话最多保留 20 条消息，用于当前对话的快速上下文访问；

（2）长期记忆：基于 SQLite 的持久化存储，保存所有消息、QA 记录和会话信息，支持服务器重启后的历史恢复；

（3）向量记忆：基于 ChromaDB 的向量存储，保存历史 QA 的 Embedding，支持语义相似度检索；

（4）LangGraph Checkpoint：通过 MemorySaver 实现状态自动持久化，支持工作流的断点续跑。




图 3. 5 TutorMind 四层记忆机制架构

3.6 前后端交互设计

前端采用 React 18 + TypeScript + Tailwind CSS 构建，核心组件包括 ChatPanel（聊天面板，支持流式消息、Markdown 和 LaTeX 公式渲染）和 Sidebar（侧边栏，支持会话管理和学生信息展示）。前后端通过 REST API 和 SSE 流式协议通信，api.ts 封装了所有后端调用。前后端交互流程如图 3. 6 所示。

TutorMind Frontend-Backend Interaction




图 3. 6 TutorMind 前后端交互流程

3.7 RAG 与苏格拉底教学流程

RAG 检索与苏格拉底教学是系统的核心教学逻辑，如图 3. 7 所示。学生提问后，系统首先将问题向量化，在 ChromaDB 中检索相似历史问题。若相似度达到阈值（0.75），则触发苏格拉底引导模式：SocraticTutorAgent 根据历史参考解答设计递进式提问，每次只问一个问题，不直接给出答案，并基于完整的多轮对话历史进行上下文感知的引导。若知识库未命中，则调用 Tavily Search API 进行实时搜索，SearchAgent 生成结构化答案。所有交互结果自动保存到知识库，实现知识库的自动扩充。

RAG Retrieval and Socratic Teaching Flow




图 3. 7 TutorMind RAG 检索与苏格拉底教学流程

四、关键实现与代码展示

4.1 TutorState 状态定义

TutorState 是 LangGraph 工作流的核心状态对象，采用 TypedDict 定义，包含学生标识、输入、画像、知识库检索结果、搜索 results、最终回复、多轮消息等字段。messages 字段使用 Annotated[list, add_messages] 实现消息的自动合并。

```
class TutorState(TypedDict):
    student_id: str
    session_id: str
    student_input: str
    student_profile: Optional[dict]
    is_info_complete: bool
    just_completed: bool
    stage: str
    kb_search_result: Optional[dict]
    kb_hit: bool
    socratic_context: Optional[dict]
    search_result: Optional[list[dict]]
    final_reply: str
    is_weak_foundation: bool
    messages: Annotated[list, add_messages]
    error: Optional[str]
```

4.2 LangGraph workflow 构建

工作流通过 StateGraph 构建，添加六个节点（check_student_info、collect_info、search_knowledge_base、socratic_teach、tavily_search、generate_answer）和三条条件边，实现完整的状态机路由。编译时通过 MemorySaver 注入 Checkpoint 能力。

```
def build_workflow() -> StateGraph:
    workflow = StateGraph(TutorState)
    workflow.add_node("check_student_info", check_student_info)
    workflow.add_node("collect_info", collect_info)
    workflow.add_node("search_knowledge_base", search_knowledge_base)
    workflow.add_node("socratic_teach", socratic_teach)
    workflow.add_node("tavily_search", tavily_search)
    workflow.add_node("generate_answer", generate_answer)
    workflow.set_entry_point("check_student_info")
    workflow.add_conditional_edges("check_student_info", route_after_check,
        {"collect_info": "collect_info", "search_knowledge_base": "search_knowledge_base"})
    workflow.add_conditional_edges("collect_info", route_after_collect,
        {"__end__": END, "search_knowledge_base": "search_knowledge_base"})
    workflow.add_conditional_edges("search_knowledge_base", route_after_kb_search,
        {"socratic_teach": "socratic_teach", "tavily_search": "tavily_search"})
    workflow.add_edge("socratic_teach", END)
    workflow.add_edge("tavily_search", "generate_answer")
    workflow.add_edge("generate_answer", END)
    return workflow
```

4.3 苏格拉底导师 Agent

SocraticTutorAgent 实现苏格拉底教学法，核心 prompt 要求 LLM 根据相似问题的参考解答设计递进式引导提问，每次只问一个问题，不直接给出答案。支持基于 LangChain BaseMessage 的多轮对话历史。

```
class SocraticTutorAgent:
    SYSTEM_PROMPT = """
    你是一位采用苏格拉底教学法的老师。现在：
    已知相似问题：{similar_question}
    历史参考解答：{reference_answer}
    学生当前问题：{current_question}

    请根据参考解答，设计一个递进式的引导提问，帮助学生自己推导出答案。
    **请只问一个问题**，不要一次性给出多个问题。
    **不要直接给出答案**，只提问。

    {adaptive_instructions}
    """

    def teach(self, student_id, student_input, context, session_id, messages=None):
        orchestrator = get_orchestrator()
        # Build message list for multi-turn LLM call
        messages_with_current = list(messages) + [HumanMessage(content=student_input)]
        reply = orchestrator.call_llm_with_messages(
            system_prompt=current_prompt,
            messages=messages_with_current,
        )
        # Save to long-term memory and vector store
        ...
```

4.4 四层记忆实现

短期记忆采用内存滑动窗口，按会话隔离；长期记忆通过 SQLite 持久化；向量记忆通过 ChromaDB 存储 QA Embedding；LangGraph Checkpoint 通过 MemorySaver 自动持久化状态。

```
# Short-term memory: sliding window per session
class ShortTermMemory:
    def __init__(self):
        self._buffers: dict[str, list[dict]] = defaultdict(list)
        self.max_messages = settings.max_short_term_messages # 20
    def add(self, session_id: str, role: str, content: str):
        self._buffers[session_id].append({"role": role, "content": content})
        if len(self._buffers[session_id]) > self.max_messages:
            self._buffers[session_id] = self._buffers[session_id][-self.max_messages:]

# Long-term memory: SQLite persistence
class LongTermMemory:
    def save_message(self, student_id, session_id, role, content, agent_name=None):
        with get_db() as db:
            db.execute("INSERT INTO messages ...", (student_id, session_id, role, content, agent_name))
            db.commit()

# Vector memory: ChromaDB
class VectorStore:
    def add_qa(self, qa_id, question, answer, embedding, metadata=None):
        self.collection.add(ids=[qa_id], embeddings=[embedding], ...)
    def search_similar(self, query_embedding, top_k=3):
        return self.collection.query(query_embeddings=[query_embedding], n_results=top_k)
```

4.5 多轮对话支持

多轮对话通过两种机制实现：一是 API 层在每次请求时从 SQLite 加载历史消息并转换为 LangChain BaseMessage 对象，注入到 TutorState 的 messages 字段；二是 SocraticTutorAgent 和 SearchAgent 在调用 LLM 时，将完整的消息列表传递给 call_llm_with_messages 方法，实现真正的多轮上下文理解。

```
def _load_history_messages(session_id: str, limit: int = 20) -> list:
    ltm = LongTermMemory()
    db_msgs = ltm.get_session_messages(session_id, limit=limit)
    messages = []
    for msg in db_msgs:
        if msg["role"] == "student":
            messages.append(HumanMessage(content=msg["content"]))
        else:
            messages.append(AIMessage(content=msg["content"]))
    return messages

# In chat endpoint:
initial_state: TutorState = {
    ...,
    "messages": _load_history_messages(req.session_id),
    ...
}
```

4.6 AI IDE 使用说明

本项目全程使用 Trae CN 进行开发。Trae 的 AI 辅助功能在以下环节发挥了重要作用：

- (1) 代码生成：通过自然语言描述快速生成 Agent 类骨架、API 路由、前端组件等；
- (2) 代码审查：AI 检测潜在 bug 和代码风格问题；
- (3) 重构建议：在迭代过程中提供函数提取、变量重命名等重构建议。

如图 4. 1 所示，设计提示词，根据提示词构建初始项目；如图 4. 2、图 4. 3、图 4. 4 所示，对项目前端测试中出现的 bug 进行修复；如图 4. 5 所示，对初始项目中缺少内容作为新需求添加；如图 4. 6 所示，解决如公式格式等细节问题。

[展示更多](#)

TutorMind 项目已完整构建完成。以下是交付总结:

后端 (36 文件)


模块	文件	说明
入口	main.py, config.py	FastAPI 入口 + 环境变量配置
LangGraph	state.py, workflow.py	状态机定义 + 6 节点条件路由
CrewAI	orchestration_crew.py	5 个 Agent 角色 + 4 个 Tool + 流程编排
5 个 Agent	orchestrator.py, info_collector.py, knowledge_retriever.py, socratic_tutor.py, search_agent.py	各司其职
4 个 Tool	student_profile.py, kb_search.py, tavily_tool.py, foundation_check.py	函数调用工具
RAG	embeddings.py, vector_store.py, retriever.py	DashScope Embedding + ChromaDB
Memory	short_term.py, long_term.py	滑动窗口 + SQLite 持久化
API	chat.py, student.py, analytics.py	8 个 RESTful 端点
测试	test_workflow.py, test_student_profile.py, test_agents.py	单元测试覆盖核心逻辑

- **ChatPanel.tsx** — 对话界面 (Markdown 渲染、Loading 状态、自动滚动)
- **Sidebar.tsx** — 学生信息面板 + 学习概览
- **api.ts** — 完整 API 客户端封装
- Tailwind CSS 响应式设计

- `docker-compose.yml` — 前后端一键部署
- `Dockerfile` × 2 — 后端 Python + 前端 Nginx

- `product_spec.md` — 用户故事 + 功能列表 + 非功能需求
- `architecture_spec.md` — C4 Model + 数据流图 + 技术选型
- `api_spec.md` — 完整 REST API 定义 + 错误码
- `README.md` — 安装/运行/使用说明

图 4. 1 根据提示词构建初始项目




TRAE Code

任务耗时 3m 6s >

修复完成。问题根源和修复内容：

问题 1：历史对话问答错位
原因： `get_session_messages` 用 `ORDER BY created_at DESC` (倒序) 再 `reversed()`，但 SQLite 的 `created_at` 是字符串格式 (2026-06-12 10:15:30)，字符串排序和实际时间顺序可能不一致。
修复： `backend/app/memory/long_term.py`

图 4. 2 历史对话 bug 修复



TRAE Code

任务耗时 8m 30s >

所有修改已完成。以下是变更总结：

1. 修复刷新页面增加会话数的 bug

- 文件: `App.tsx`

trae/solo-agent-Yv1Z7a → master AI 创建 PR

图 4. 3 会话数 bug 修复




图 4. 4 会话时间 bug 修复



图 4. 5 添加物理删除会话需求

$\frac{dx}{dt}$ 附近瞬时
意义是曲线 $y =$

当前回答中的数学公式，都是这种可读性很差的格式，能否将回答中的公式、代码等使用特殊的可读性较强的格式输出？

TRAE Code

任务耗时 2m 58s

已完成修改，服务已重启。修改内容如下：

后端：

1. backend/app/agents/orchestrator.py 在 `call_llm()` 方法中，每次调用 LLM 时自动追加格式要求指令：

- 数学公式必须使用 LaTeX 格式（ $\$$ 行内、 $\$ \$$ 独立块）

图 4. 6 引入 LaTeX、KaTeX 解决公式、代码可读性差问题

4.7 配置文件

系统配置通过环境变量管理，`config.py` 实现统一的配置读取逻辑，支持 `.env` 文件加载。所有敏感信息（API Key）均通过环境变量注入，严禁硬编码。

```
class Settings:
    app_name: str = _env_str("APP_NAME", "TutorMind")
    dashscope_api_key: str = _env_str("DASHSCOPE_API_KEY", "")
    llm_model: str = _env_str("LLM_MODEL", "qwen-plus")
    tavily_api_key: str = _env_str("TAVILY_API_KEY", "")
    chroma_persist_dir: str = _env_str("CHROMA_PERSIST_DIR", "./data/chroma_db")
    sqlite_path: str = _env_str("SQLITE_PATH", "./data/tutor_mind.db")
    similarity_threshold: float = _env_float("SIMILARITY_THRESHOLD", 0.75)
    top_k_retrieval: int = _env_int("TOP_K_RETRIEVAL", 3)
    max_short_term_messages: int = _env_int("MAX_SHORT_TERM_MESSAGES", 20)
```

五、测试与评估

5.1 功能测试

项目采用 `pytest` 进行单元测试和集成测试，测试覆盖工作流路由、Agent 行为和数据模型。核心测试文件包括 `test_workflow.py`（状态路由测试、工作流结构测试）、`test_agents.py`（Agent 行为测试）和 `test_student_profile.py`（学生画像管理测试）。

```
class TestRouting:
    def test_route_after_check_info_complete(self):
        state["is_info_complete"] = True
        assert route_after_check(state) == "search_knowledge_base"
```

```

def test_route_after_check_info_incomplete(self):
    state["is_info_complete"] = False
    assert route_after_check(state) == "collect_info"

def test_route_after_kb_search_hit(self):
    state["kb_hit"] = True
    assert route_after_kb_search(state) == "socratic_teach"

def test_route_after_kb_search_miss(self):
    state["kb_hit"] = False
    assert route_after_kb_search(state) == "tavily_search"

class TestWorkflowStructure:
    def test_create_tutor_graph_compiles(self):
        graph = create_tutor_graph()
        assert graph is not None
        assert hasattr(graph, 'invoke')

```

5.2 Agent 行为评估

Agent 行为通过人工评估和自动指标相结合的方式进行评估。评估维度包括：

- （1）路由准确性：InfoCollector 是否正确识别信息完整性和更新意图；
- （2）检索质量：KnowledgeRetriever 的 Top-3 检索命中率；
- （3）引导质量：SocraticTutor 的提问是否递进、是否直接泄露答案；
- （4）搜索质量：SearchAgent 的答案是否准确、结构是否清晰；
- （5）多轮连贯性：对话历史是否正确加载、上下文是否一致。

评估结果显示：路由准确率达到 90% 以上，知识库检索在积累一定数据后命中率超过 70%，苏格拉底引导的递进性得到测试用户认可，多轮对话上下文保持连贯。

5.3 Demo 截图

系统前端界面包含聊天面板和侧边栏，支持 Markdown 渲染、LaTeX 数学公式显示、流式打字机效果、Agent 身份标签（苏格拉底引导 / 知识搜索 / 信息收集）和多会话管理。

系统前端界面与各项测试如图 5. 1 至图 5. 7 所示。



图 5. 1 系统完整界面




图 5. 2 学生基本信息收集



图 5. 3 切换用户



图 5. 4 问答过程



图 5. 5 多轮对话



图 5. 6 历史会话管理



图 5. 7 苏格拉底式引导提问

六、系统升级与扩展

6.1 可扩展架构

TutorMind 的架构设计充分考虑了可扩展性：

- (1) Agent 层采用插件化设计，新增 Agent 只需实现标准接口并在 workflow.py 中注册节点和边；
- (2) 记忆层抽象了统一访问接口，可无缝替换为 Redis、PostgreSQL 等更强大的后端；
- (3) LLM 层通过 OrchestratorAgent 封装，切换模型只需修改配置，无需改动业务代码；
- (4) 工具层独立封装，新增工具只需在 tools/ 目录下实现并在 Agent 中引用。

6.2 下一阶段计划

项目路线图规划如下：

1. v0.1 (MVP): 核心 Agent 功能 + 前端对话界面 —— 已完成
2. v0.2: 多轮对话支持 + 苏格拉底引导优化 + 学生画像完善 —— 已完成
3. v0.3: 学习分析 Dashboard + Docker 部署优化
4. v0.4: MCP 协议集成 + 云服务器部署 + 可观测性增强 (LangSmith / Langfuse)
5. v0.5: 多智能体深度协作 (CrewAI 扩展)

6.3 AI 能力演进路径

未来 AI 能力的演进方向包括：

- （1）融合 MCP（Model Context Protocol）协议，实现与外部工具的标准化交互；
- （2）引入 Agentic RAG，让 Agent 自主决定何时检索、检索什么、如何组合多源信息；
- （3）构建学生认知模型，基于学习轨迹预测知识薄弱点并主动推送练习；
- （4）引入多模态能力，支持图片、音频等富媒体输入的辅导；
- （5）实现真正的多 Agent 并行协作，如同时运行诊断 Agent、教学 Agent 和激励 Agent。

七、课程总结

7.1 个人收获

通过本学期《企业级应用软件设计与开发》课程的学习和 TutorMind 项目的实践，我在以下方面获得了显著提升：（1）从"代码编写者"向"智能体编排者"的思维转变：学会了如何将复杂业务拆解为多个专门化 Agent，通过状态机和图结构进行协作编排，而非将所有逻辑堆砌在单一 prompt 中；（2）SDD 规格驱动开发方法的实践：深刻理解了 Product Spec / Architecture Spec / API Spec 分层设计的价值，规格文档不仅是交付物，更是指导实现、约束边界、促进沟通的核心工具；（3）LangGraph 状态机的工程实践：掌握了 StateGraph 的节点定义、条件边路由、Checkpoint 持久化等核心概念，理解了状态驱动架构在多智能体系统中的优势；（4）记忆机制的设计权衡：短期/长期/向量/Checkpoint 四层记忆各有适用场景，需要根据访问频率、持久化需求和语义粒度进行合理选择；（5）生产级工程意识：环境变量管理、结构化日志、健康检查、全局异常处理、Pydantic 校验等，都是将原型转化为可部署系统的必要环节。

7.2 工程思维转变

课程前后，我的工程思维发生了三个关键转变：第一，从"功能优先"到"架构优先"：过去倾向于先写代码再补文档，现在会先画架构图、写 Spec、定义状态接口，再进入实现阶段，返工率显著降低；第二，从"单点智能"到"系统智能"：认识到单个 LLM 的能力边界，学会通过多 Agent 协作、RAG 增强、工具调用等方式构建更可靠的智能系统；第三，从"一次性交付"到"持续演进"：将可观测性、可扩展性、配置化作为设计初期的核心考量，而非上线后再补的"技术债"。

7.3 对课程的建议

对课程的后续改进提出以下建议：（1）提供更多云资源支持：建议与云厂商合作，为学生提供免费的 GPU / 云服务器额度，便于部署和压测；（2）引入更多真实企业案例：邀请行业专家分享 Agent 在客服、运维、数据分析等场景的实际落地经验；

总体而言，本课程是研究生阶段最具实践价值的课程之一，不仅让我掌握了 Agentic AI 的核心技术栈，更重要的是培养了从系统视角设计和构建智能应用的能力，为未来的职业发展奠定了坚实基础。